

RAPORT Z PROJEKTU: KLASYFIKACJA ZBIORU SZTUCZNEGO ARTIFICIAL

Przedmiot: Wstęp do Uczenia Maszynowego

Autor (Numer Indeksu): 333076

Termin oddania projektu: 06.01.2026 ²

1. Wstęp i cel projektu

Celem niniejszego opracowania jest przedstawienie procesu budowy modelu klasyfikacyjnego o najwyższej mocy predykcyjnej dla sztucznie wygenerowanego zbioru danych. Zgodnie z wytycznymi, główną miarą sukcesu jest zrównoważona dokładność (*balanced accuracy*), która pozwala rzetelnie ocenić model przy podziale na dwie klasy. Wyzwaniem projektowym była obecność 100 zmiennych objaśniających, wśród których ukryto zmienne istotne oraz kolumny zbędne (szum informacyjny).


2. Eksploracyjna analiza danych (EDA)

Przed przystąpieniem do modelowania przeprowadzono szczegółową analizę zbioru treningowego (1500 obserwacji):

Rozkład klas: Etykiety w zbiorze treningowym są rozłożone niemal równomiernie (Klasa 1: 755 wystąpień, Klasa 2: 745 wystąpień), co ułatwia optymalizację pod kątem wybranej metryki.

Analiza braków: Dane są kompletne; nie stwierdzono brakujących wartości w żadnej ze 100 kolumn.

Macierz korelacji: Analiza korelacji Pearsona wykazała brak silnych zależności liniowych pomiędzy cechami V1-V100 a zmienną docelową. Wskazuje to na konieczność zastosowania modeli zdolnych do wychwytywania nieliniowych wzorców.



3. Metodologia i idea wyboru modelu

Podstawową ideą procesu badawczego było przetestowanie szerokiego spektrum algorytmów i wyłonienie tego, który najlepiej poradzi sobie podczas krosvalidacji mierzonej w balanced accuracy. Proces podzielono na etapy:

3.1. Screening i eliminacja modeli

W pierwszej fazie przetestowano klasyfikatory o różnych zasadach działania:

Modele liniowe i dyskryminacyjne: Regresja Logistyczna, LDA oraz QDA wykazywały niską skuteczność ze względu na brak liniowej separowalności danych.

Modele oparte na drzewach: Random Forest (RF) oraz Gradient Boosting (GBM) uzyskały obiecujące wyniki, stając się podstawą do dalszych prac.

Modele oparte na odległości: Algorytm StandardScaler -> SelectFromModel z RF -> k-Nearest Neighbors (k-NN) wykazał najwyższy potencjał (uzyskiwały najwyższe wyniki)

3.2. Wyłonienie najlepszych potoków (Shortlist)

Na podstawie wstępnej krosvalidacji wybrano trzy potoki do intensywnego tuningu:

k-NN Pipeline: Średni wynik ok. 0.90 BA.

Random Forest Pipeline: Średni wynik 0.8674 BA.

Gradient Boosting Pipeline: Średni wynik 0.8440 BA.

4. Proces eksperymentalny i optymalizacja

Po wyłonieniu k-NN jako faworyta, skupiono się na "dociągnięciu" jego wyniku poprzez optymalizację potoku przetwarzania.

4.1. Budowa ostatecznego pipeline'u z uzasadnieniem teoretycznym

4.1.1. Brak liniowości a wybór modelu k-NN

Przeprowadzona analiza korelacji Pearsona wykazała niemal całkowity brak liniowych zależności pomiędzy cechami objaśniającymi a zmienną docelową.

- **Wniosek z analizy:** Klasyczne modele parametryczne (np. Regresja Logistyczna) opierające się na liniowej separowalności nie mogły przynieść zadowalających rezultatów.
- **Uzasadnienie k-NN:** Wybór algorytmu k-Najbliższych Sąsiadów wynika z faktu, że jest on modelem nieparametrycznym, podejmującym decyzje na podstawie lokalnej topologii danych. Skoro globalny trend liniowy nie istnieje, model musi

polegać na lokalnych klastrach i podobieństwie geometrycznym punktów, co k-NN realizuje natywnie.

4.1.2. Selekcja cech jako filtr szumu informacyjnego

Zgodnie z opisem projektu, zbiór zawiera "kolumny zbędne". Twoja analiza statystyczna (`describe()`) wykazała, że wiele zmiennych ma podobne rozkłady, co utrudnia ręczną selekcję.

- **Wniosek z analizy:** Konieczne było zastosowanie metody, która potrafi ocenić ważność cechy w sposób nieliniowy.
- **Uzasadnienie `SelectFromModel (RF)`:** Wykorzystanie lasu losowego do selekcji pozwoliło na ocenę interakcji między zmiennymi (tzw. *feature importance*), których nie widać na macierzy korelacji Pearsona. Próg $1.4 * \text{mean}$ zadziałał jak filtr górnoprzepustowy, usuwając zmienne o niskiej wartości informacyjnej i redukując wymiarowość problemu z 100 do tylko tych najbardziej "istotnych" zmiennych.
-

4.1.4. Stabilizacja granic decyzyjnych (SMOTE i Distance Weighting)

Mimo względnego balansu klas (755 vs 745), zbiór 1500 obserwacji w przestrzeni 100-wymiarowej jest zbiorem rzadkim (*sparse data*).

- **Wniosek z analizy:** Przy tak małej próbie granice między klasami mogą być poszarpane i podatne na wpływ pojedynczych punktów odstających.
- **Uzasadnienie SMOTE i wag:** SMOTE pozwoliło na syntetyczne "zagęszczenie" obszarów granicznych, co ułatwiło modelowi naukę stabilnych reguł. Z kolei wprowadzenie wag distance w klasyfikatorze k-NN sprawiło, że punkty leżące bliżej obserwacji testowej mają realnie większy wpływ na wynik, co teoretycznie czyni predykcję bardziej odporną na szum obecny w dalszym sąsiedztwie.

4.1.5 Podsumowanie teoretyczne

Synergia tych kroków – od nieliniowej selekcji (RF), po lokalną klasyfikację (k-NN) – stanowiła jedyną skuteczną odpowiedź na specyficzne cechy zbioru *artificial* zidentyfikowane w EDA. To właśnie to kompleksowe podejście pozwoliło na osiągnięcie stabilnego wyniku 90% Balanced Accuracy w krosvalidacji.

4.2. "Sufit" modelu i stabilność

Podczas optymalizacji zauważono, że wynik stabilizuje się na poziomie 90%. Dalsze próby komplikowania modelu lub jeszcze agresywniejszej selekcji cech nie przynosiły poprawy, co sugeruje osiągnięcie granicy możliwości predykcyjnych dla dostępnego zbioru 1500 próbek.

5. Wyniki i walidacja

Ostateczną weryfikację przeprowadzono metodą Repeated Stratified K-Fold (5 foldów, 20 powtórzeń), co dało 100 niezależnych estymacji:

Średni Balanced Accuracy: 0.90 (90%).

Stabilność: Wyniki foldów mieściły się w przedziale 0.86 – 0.93, co potwierdza wysoką zdolność generalizacji.

Prawdopodobieństwa: Model wygenerował wektor płynnych prawdopodobieństw dla 500 obserwacji testowych, unikając dyskretnych skoków typowych dla prostego k-NN.

6. Podsumowanie i wnioski

Zastosowanie wieloetapowego potoku przetwarzania pozwoliło na skuteczne oddzielenie sygnału od szumu w sztucznym zbiorze danych. Kluczowym elementem sukcesu okazała się nieliniowa selekcja cech oparta na lasach losowych oraz wybór algorytmu k-NN, który najlepiej zidentyfikował ukryte struktury danych. Opracowany model charakteryzuje się wysoką stabilnością i wysoką mocą predykcyjną, co czyni go optymalnym rozwiązaniem dla postawionego zadania